



Construcción de estadísticas experimentales con SAE



GOBIERNO DE COLOMBIA

05 de junio de 2023



Ecosistema de datos de las estadísticas oficiales - SEN

- Sistema Estadístico Nacional – SEN
 - Subsistema Departamental
 - Subsistema Municipal

○ Usuarios de información estadística

 - * Subsistema de otras entidades territoriales
 - Provincias
 - Áreas metropolitanas
 - Territorios indígenas
 - Territorio colectivo de comunidades negras
 - Asociaciones de municipios
 - Territorios PDET

VIACIÓ N PARA TODOS



¹ **Artículo 155 de la Ley 1955 de 2019.** Desde la oferta, además de las entidades del orden nacional y subnacional que producen información estadística; están las personas jurídicas, públicas o privadas, que prestan servicios públicos y las personas jurídicas que posean, produzcan o administren registros administrativos en el desarrollo de su objeto social, que sean insumos necesarios para la producción de estadísticas oficiales. Dentro de las organizaciones de la sociedad civil (OSC) se incluyen: las organizaciones no gubernamentales (ONG), entidades sin ánimo de lucro (ESAL) las cuales a su vez, incluyen las cámaras de comercio; gremios; organizaciones sociales, comunitarias, sindicales, de profesionales, étnicas, académicas; entre otras.



Toma de decisiones basadas en información

Dada la alta disponibilidad de datos se genera una mayor demanda de análisis con el fin de **tomar decisiones basados en datos**. En la política pública se está dando el mismo enfoque lo que aumenta la demanda de información por parte de otras entidades, la academia, organismos gubernamentales y la ciudadanía en **publicar información con mayor desagregación y detalle**.




Pasos para la implementación



1



Identificación de los planes de interés y sus dominios



Interés estadístico del nuevo Plan Nacional de Desarrollo - PND 2022-2026

Las principales necesidades de información y análisis de datos son:

Censo Económico – 2024.


Conteo Intercensal de Población – 2025.

Mayor granularidad de las estimaciones. Estadísticas oficiales para grupos poblacionales más específicos como víctimas, género, etnicidad, pero también estimaciones a niveles más desagregados de nivel geográfica como municipios, localidades, barrios para todas las OOEE no sólo del DANE sino del SEN para el seguimiento del cumplimiento de los indicadores.



Niveles de desagregación definidos en el PND 2022-2026

De acuerdo con las bases del Plan Nacional de Desarrollo 2022-2026 “**Colombia potencia mundial de la vida**”, se cuenta con los siguientes actores diferenciales para el cambio:



Genero
Mujer
LGBTIQ+



Ciclo de vida
Niños y niñas
Jóvenes



Discapacidad



Víctimas



Grupos étnicos



Territorio
Municipios
Ruralidad
PDET



Campesinos



Economía
Popular




Niveles de desagregación requeridos a través de los ODS

Los indicadores de los Objetivos de Desarrollo Sostenible deberían desglosarse, siempre que fuera pertinente, por:

- **Ingreso**
- **Sexo**
- **Edad**
- **Raza**
- **Etnicidad**
- **Estado migratorio**
- **Discapacidad**
- **Ubicación geográfica**



u otras características, de conformidad con los Principios Fundamentales de las Estadísticas Oficiales (resolución 68/261 de la Asamblea General).




2

Definición de las fuentes de información y construcción de covariables


D

Fuentes de información disponibles para la integración de datos




Censos

CENSO NACIONAL
DE POBLACIÓN Y VIVIENDA 2018 - COLOMBIA



Registros
administrativos


RELAB
Variables
municipales



Encuestas




ENA



Información
geoespacial




Imágenes
satelitales



Fuentes
alternas

Web scraping
APPS
IA
Big Data


Fuentes secundarias disponibles y su uso estadístico



El país tiene **527 Registros administrativos** producidos por **95 entidades**.

* OO.EE y RR.AA en estado activo

Los datos e información estadística del SEN son activos disponibles para la investigación aplicada y la toma de decisiones.




El DANE aprovecha estadísticamente **233 Registros administrativos**.

Fuente: Inventario de usos de registros administrativos 2022, revisado al 3 de octubre de 2022



2. Fortalecimiento de marcos

Aplicación de técnicas alternativas sobre **imágenes satelitales y de dron**, para la **actualización y fortalecimiento del Marco Maestro Rural Agropecuario (MMRA)**



Logros 2020

- Con base en imágenes Sentinel-2, imágenes de dron, y muestras de entrenamiento recolectadas en campo, **se aplicó el algoritmo de Random Forest para la clasificación supervisada basada en píxeles de las coberturas del suelo.**
- **Mejoras en la precisión de clasificación** (hasta el 3%) y en la delimitación de coberturas.
- Método reemplaza fotointerpretación masiva previa por una **clasificación supervisada semiautomatizada a través del procesamiento en la nube y ejecución de scripts.**



Logros 2021

- Clasificación de imágenes satelitales (Sentinel-2, Sentinel-1, PlanetScope) aplicando *Random Forest*.
- Se estimaron 521 ha de **papa** (Villapinzón – Cundinamarca) y 483,6 ha de **fríjol** (San Gil – Santander) con precisiones generales del 82% y 76%, respectivamente.
- Aplicación de los scripts procesamiento para la **clasificación e identificación de grandes coberturas** de la tierra de forma masiva. Mejoras en la precisión de estimación de coberturas gruesas como bosques y pastos.



Logros 2022


- Clasificación con modelos ML supervisados *Random Forest* y *XGBoost*.
- Se estimaron más de 5 mil ha de **maíz** y 408 ha de **piña** en la zona de estudio (San Martín y Granada – Meta) con **precisiones generales superiores al 90%**, para la actualización de cultivos de dominio.
- Modelo para la identificación de cultivos de interés disponible para puesta en producción.



Fuentes de datos para los modelos de áreas pequeñas

Uno de los pasos más importantes de la estimación en áreas pequeñas es la definición de las fuentes de información a utilizar. En la bibliografía autores como Villa Juan-Albacea, Zita (2009), Das, S., & Haslett, S. (2019), las naciones unidas, la CEPAL, entre otros. Recomiendan el uso tanto de información censal como de registros administrativos, dado que, la inclusión de registros administrativos permite una mejor estimación de los modelos en años no censales.

	Ventajas	Desventajas
Fuentes censales	Se posee información tanto a nivel de unidad como de área para toda la población Es validado a través de metodologías estadísticas para evitar sesgos	Se actualiza como mínimo cada 10 años Su realización es muy costosa
Registros administrativos	Se actualiza recurrentemente Existen múltiples mediciones a nivel de registros administrativos	Su objetivo es tener un registro de la población por lo cual no fue diseñado para fines estadísticos Puede tener sesgos no medibles



3

Definición del modelo de estimación de áreas pequeñas



Modelo básico de estimación en áreas pequeñas

Modelo de Fay-Herriot es un modelo de área basado en los modelos lineales mixtos. Donde

Estimación directa

$$y_d = \mu_d + e_d$$

Tradicionalmente se tienen las estimaciones directas que usualmente no pueden estimar todos los dominios de interés

Estimación por modelos

$$\mu_d = x_d\beta + u_d$$

Sin embargo, es posible incluir información auxiliar que permita estimar dar estimaciones adecuados para estos dominios

Modelo de áreas pequeñas

$$y_d = X_d\beta + u_d + e_d$$

El uso de las ventajas del estimador directo y el estimador por modelos conllevan a un modelo mixto, denominado el modelo de áreas pequeñas



¿Cuál modelo seleccionar?

Dado el auge y la importancia que están teniendo los métodos de estimación en áreas pequeñas, es necesario realizar investigación en nuevos métodos u otras propuestas para mejorar los indicadores estimados.



Estimación en áreas pequeñas con modelos de machine learning

Con el fin de aprovechar las ventajas del Machine Learning algunos autores como Viljanen, M., Meijerink, L., Zwakhals, L., & van de Kassteele, J. (2022), Singleton, A., Alexiou, A., & Savani, R. (2020), Krennmair, P., Wurz, N., & Schmid, T. (2022). Han iniciado la investigación de como usar modelos de ML en la estimación en areas pequeñas, como por ejemplo tree-based models. Uno de los principales enfoques del ML es incluir muestras de entrenamiento y de prueba. Dado que buscan predecir correctamente la información sobre datos no observados en las muestras utilizando metodologías como validación cruzada. Uno de los modelos utilizados es el XGBoost.



Ventajas	Desventajas	
Es uno de los métodos más usados cuando se trabaja con problemas de gran dimensión tanto en individuos como en variables.	Se denomina de caja negra al no determinar la importancia de variables. Sin embargo, se puede solventar usando métodos locales como LIME.	
Reduce tiempos para la predicción de la variable de interés.	Dado que es una técnica no paramétrica es necesario estimar el ECM utilizando técnicas como Bootstrap	




3

Algunas aplicaciones en DANE

D

Fuentes de información




D

Resultados:

Mapa de la pobreza monetaria estimada con el modelo

- El mapa de la pobreza monetaria de los hogares pronosticada con el modelo de efectos aleatorios para los 1.122 municipios de Colombia
 - Más allá de las usuales ciudades capitales de los departamentos, **el mapa muestra patrones de diferenciación geográfica entre los municipios en términos de la pobreza monetaria.**
 - Estos patrones permiten distinguir aglomeraciones de municipios de baja o alta pobreza monetaria o, por el contrario, municipios que se encuentran en un extremo de la distribución rodeados por municipios en el extremo opuesto.


Nota: Resultados proximamente a ser publicados.





Resultados: estimación de la emigración internacional en áreas pequeñas (municipios) en Colombia

Se aplicó el modelo Fay-Herriot, se ajusta a la DHS 2015 según la información del censo disponible. Se calcula el EBLUP al indicador seleccionado de emigración internacional a nivel municipal, se aplica el método GVF para estimar las varianzas de los estimadores directos de PHMLA.



Fuente: DANE.



Uso de métodos anticonceptivos para población indígena

01

Homologación de variables

02

Usar los datos muestrales de la DHS para estimar el modelo


03

Usar los parámetros estimados con la información auxiliar del censo


04

Estimación de los dominios de interés

INFORMACIÓN PARA TODOS



Rao and Molina (2015). Small Area Estimation. New York: John Wiley & Sons.
SAE4SDG Toolkit <https://unstats.un.org/wiki/display/SAE4SDG/SAE4SDG>





Mapa de pobreza multidimensional

Integración de fuentes alternativas de información en el proceso estadístico



Actualmente el DANE mide:

- IPM a nivel departamento usando la encuesta de hogares anualmente
- IPM a nivel municipal usando el censo cada 10 años.


Indicador:

- IPM a nivel municipal anual

Sources:

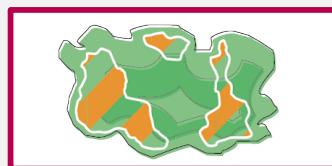
- Encuesta de hogares
- Censo
- Datos Geoespaciales

INFORMACIÓN PARA TODOS




Recolectar

- Información geoespacial como luces nocturnas, índice de vegetación, vías.




Entrada

- Clusters de la encuesta con la medida agregada de IPM




Modelo

- Modelo mixto generalizado (Geoestadístico)
- Modelo geoestadístico bayesiano



Estimación

- Población viviendo en pobreza a nivel de cluster



Resultados y validación

- Mapeo del IPM a nivel de cluster (manzanas/veredas)
- Rendimiento del modelo

4



Consistencia, comparación con las cifras oficiales y validación de expertos



¿Cómo escoger el mejor modelo?

Tanto para modelos de área como para modelos de unidad existen diferentes propuestas alrededor del mundo y se aplican diferentes estrategias para la estimación del indicador de interés. Sin embargo, surge la necesidad de como escoger el mejor modelo:

Precisión

El modelo predice bien el comportamiento de mi variable



Error de las estimaciones

Tengo un error de estimación aceptable para la publicación de resultados

Replicabilidad

Es replicable este modelo a través del tiempo

Disponibilidad de la información

¿Los registros administrativos estarán disponibles a futuro?


5



Definición del proceso y publicación de resultados



Plan de trabajo SAE



Investigación, prueba y aplicación de nuevas metodologías, como: Machine Learning y Big Data para la inclusión de variables provenientes de: fuente alternas, temporales, espaciales, registros administrativos, etc.



Ciclo de vida del dato



Fuente: basado en OCDE

Preparación de datos


Replicable para diferentes variables

- 1 Inventario de fuentes de información y mapeo de variables para la construcción de indicadores
- 2 Descarga de información y almacenamiento en servidores DANE
- 3 Extracción, transformación y carga de variables del modelo de áreas pequeñas
- 4 Análisis exploratorio de datos y análisis de calidad de datos




Proceso de revisión en Registros Administrativos

5 dimensiones en la revisión de las fuentes para asegurar la calidad del producto final: REBE



*Tomado de estándares consolidados por la DIRPEN en el marco del BLUE Enterprise and Trade Statistics (2011)

Integración de datos



Retos:

1. Efectividad de los cruce de información (Cobertura). Potenciales sesgos (*Linking Bias*)
2. Actualización de información para definir periodicidad del proceso y pertinencia en la entrega de las fuentes (Gobierno de datos a través del CAD/SEN)
3. Calidad de datos



Construcción y transformación de variables

01

Homologación de variables


- Manejar el mismo formato
- Estandarización de categorías
- Identificación de variables similares con fraseos o métodos de recolección diferentes

02

Jerarquía de la fuente de información

- Definición de la confiabilidad de la fuente por variable

(2018 Census Adjusted-REBP) /
2018 Census Adjusted



03

Actualización de información

- Complementar fuentes de información:
- Ejemplo: Nivel y grado educativo.

Grado = Línea de base
(CNPV2018) + SIMAT (2019) +
...

04

Construcción de variables


- Definición del indicador usado como covariable del modelo de estimación



Preparación de datos Ejemplo – Pobreza monetaria


Procedimiento de tablas a usar en la estimación de pobreza monetaria municipal usando SAE.

Pensando en la replicabilidad del proceso en el siguiente año de estimación






Garantizar actualización y escalamiento – Tránsito a producción estadística



Buscando un enfoque de flujo de datos (*pipeline*) para la actualización de información

Construcción de flujo de datos para el procesamiento de modelos



Fuente: <https://valohai.com/machine-learning-pipeline/>



Bibliografía

1. Corral P., Molina I., Cojocaru A., Segovia S. (2022). Guidelines to Small Area Estimation for Poverty Mapping. World Bank.
2. Das, S., & Haslett, S. (2019). A comparison of methods for poverty estimation in developing countries. *International Statistical Review*, 87(2), 368-392.
3. Dong, P., Ramesh, S., & Nepali, A. (2010). Evaluation of small-area population estimation using LiDAR, Landsat TM and parcel data. *International Journal of Remote Sensing*, 31(21), 5571-5586.
4. Ghosh, M., & Rao, J. N. (1994). Small area estimation: an appraisal. *Statistical science*, 9(1), 55-76.
5. Marchetti, Tzavidis, Permanyer, Spain, et al. (2021). METHODOLOGICAL PAPER ON MEASUREMENT ERROR USING AUXILIARY INFORMATION FOR SMALL AREA ESTIMATION, United Nations.
6. Villa Juan-Albacea, Zita (2009) : Small Area Estimation of Poverty Statistics, PIDS Discussion Paper Series, No. 2009-16, Philippine Institute for Development Studies (PIDS), Makati City
7. Viljanen, M., Meijerink, L., Zwakhals, L., & van de Kassteele, J. (2022). A machine learning approach to small area estimation: predicting the health, housing and well-being of the population of Netherlands. *International Journal of Health Geographics*, 21(1), 4.
8. Singleton, A., Alexiou, A., & Savani, R. (2020). Mapping the geodemographics of digital inequality in Great Britain: An integration of machine learning into small area estimation. *Computers, Environment and Urban Systems*, 82, 101486.
9. Krennmair, P., Wurz, N., & Schmid, T. (2022). Tree-Based Machine Learning in Small Area Estimation.